FACULTAD DE MATEMÁTICAS — UC| EYP3407

ANÁLISIS ESTADÍSTICO DEL MERCADO

Inmobiliario en Francia

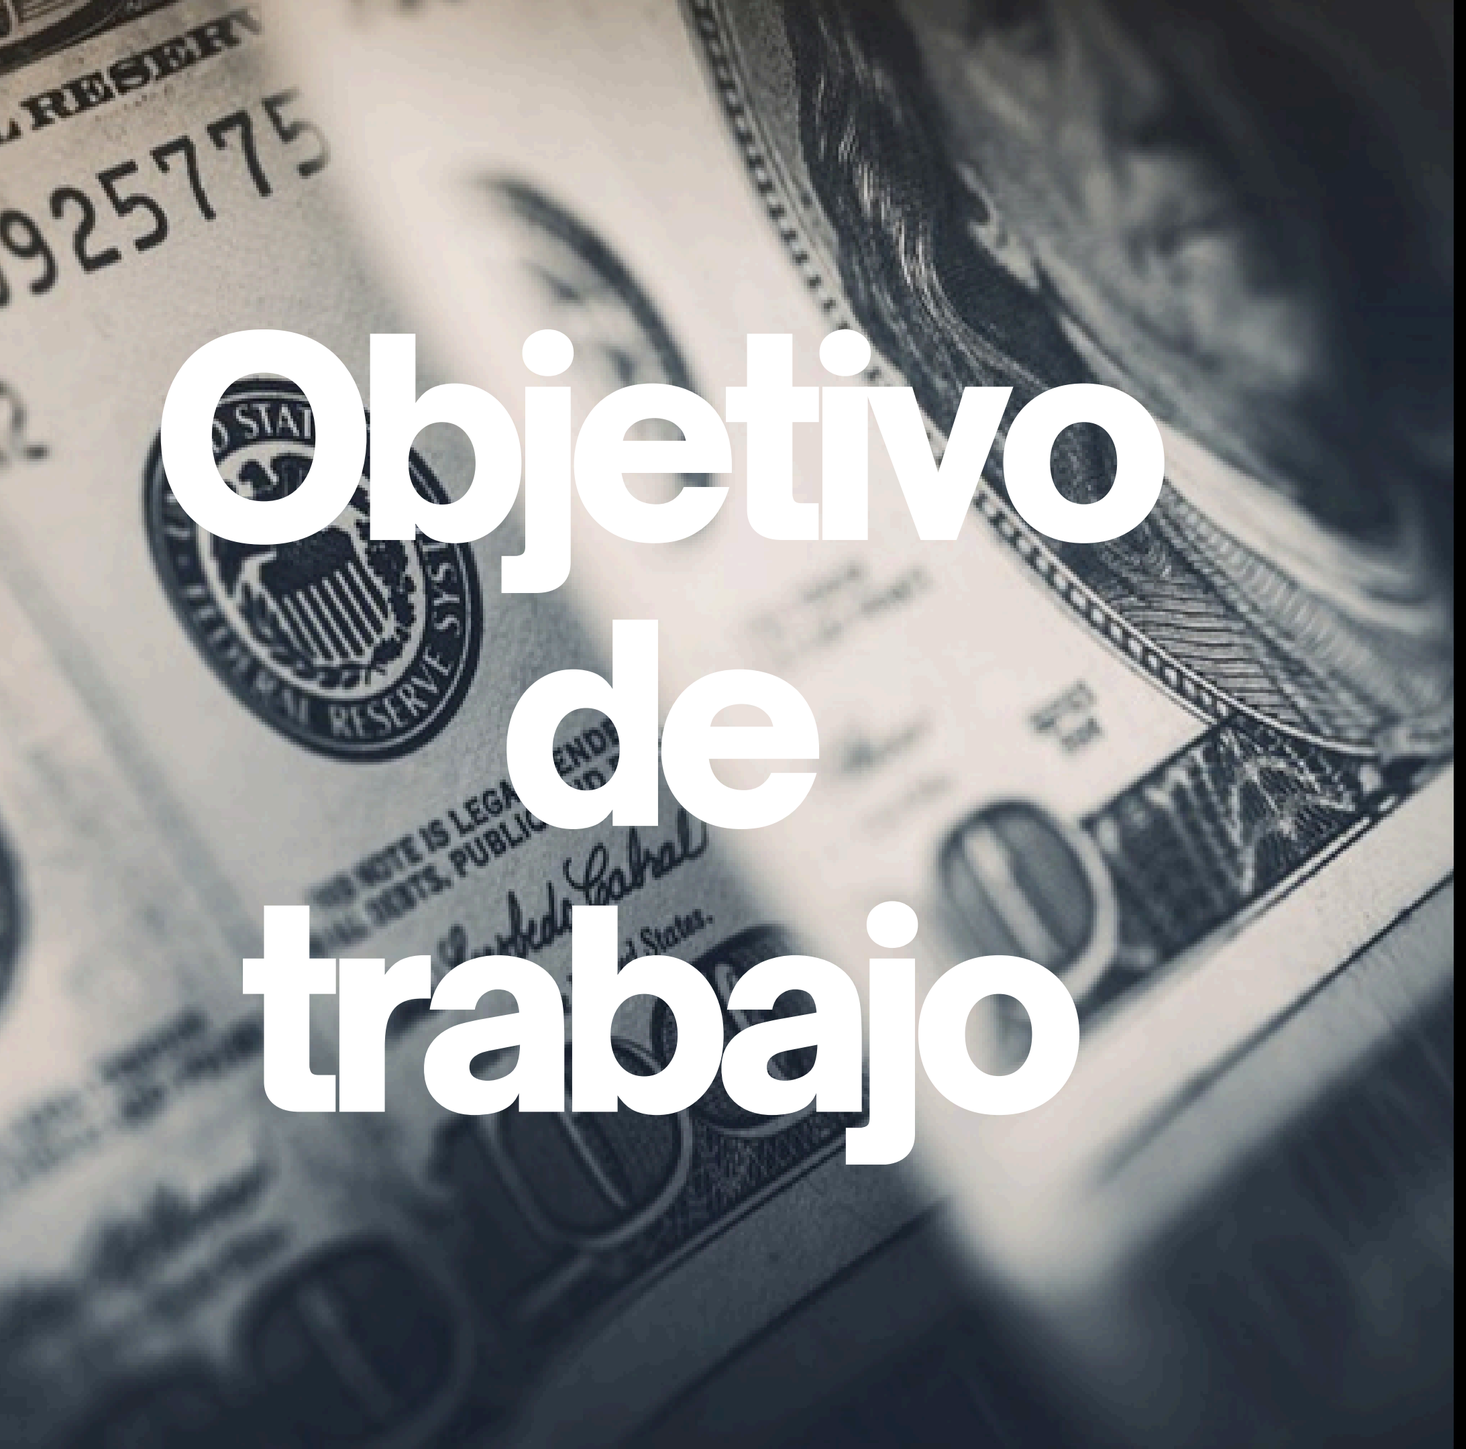


Autores

Francisca Sepúlveda • Alexander Pinto • Karina Armijo • Pía Mella

Segundo Semestre 2026

1. Contexto y construcción de los datos



Objetivo de trabajo

Evaluar y comparar la capacidad predictiva de tres metodologías sobre **transacciones residenciales** en Rhône, Francia

Base de datos

Nombre: *Demandes de valeurs foncières géolocalisées (DVF)*
Esta fue elaborada por la Dirección General de Finanzas Públicas (DGFiP)

Contiene **301.891 registros** y 40 variables, de estas 12 variables cuantitativas y 28 variables categóricas.

Los datos comprende transacciones inmobiliarias registradas **entre 2021 y 2023** en el departamento de Rhône (69), Francia.

Las variables permiten caracterizar las transacciones inmobiliarias desde cinco dimensiones: **temporal, geográfica, física, de copropiedad y de uso de suelo.**



Identificación

Población

Conjunto de transacciones inmobiliarias realizadas en el departamento de Rhône (código 69), Francia, durante el período 2021-2023.

Muestra

Los 301.891 registros disponibles en la base de datos DVF

Unidad

(Variable respuesta)

Cada operación de transacción inmobiliaria residencial individual

VALOR INMOBILIARIO

Variable respuesta: `valeur_fonciere`

Corresponde variable de naturaleza **cuantitativa discreta**.

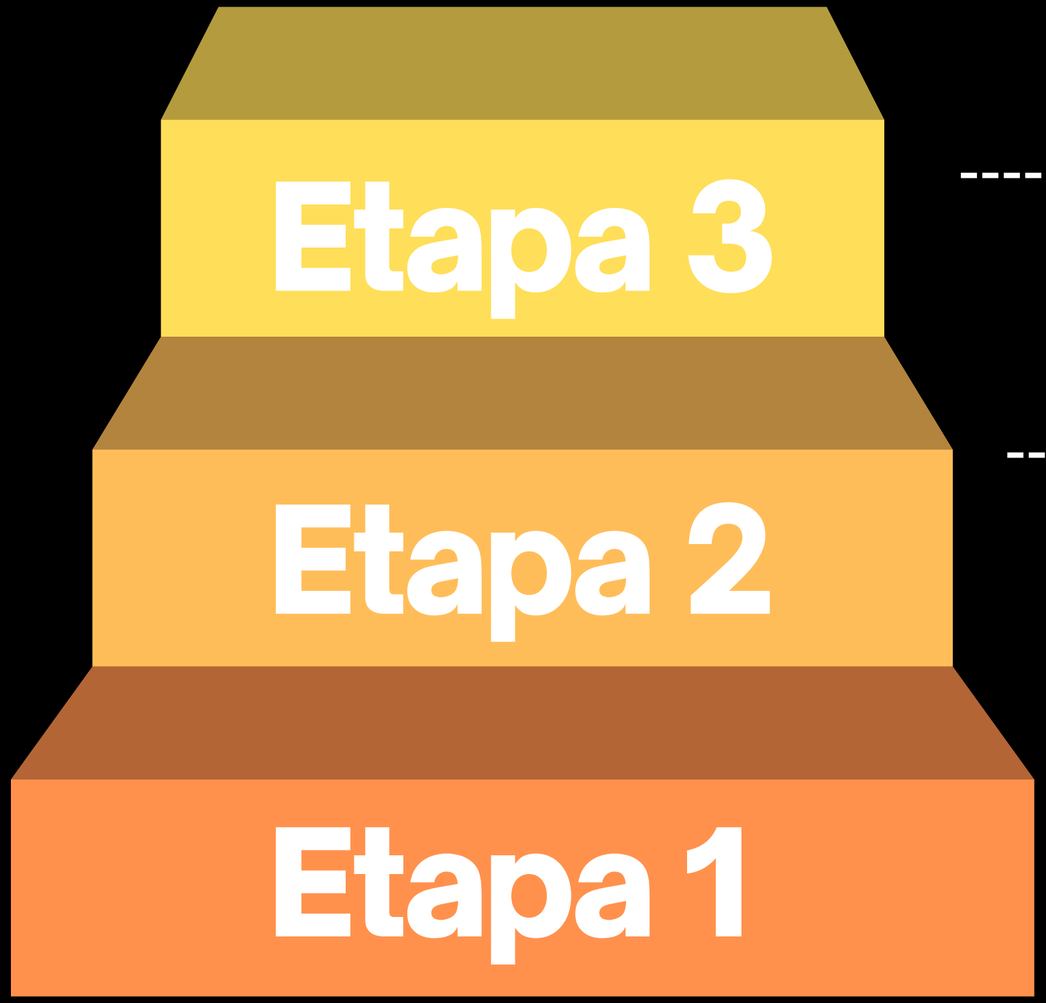
Escala original → Fuerte asimetría positiva con sesgo extendido a la derecha.

Transformación: Escala Logarítmica → Aproximación a la distribución normal



LIMPIEZA DE DATOS

Proceso de Construcción de la Muestra



ETAPA 3: DEPURACIÓN FINAL

Imputación espacial/habitaciones y exclusión de <1.000 €/m² y <8 m².

ETAPA 2: CONSOLIDACIÓN

Agrupación por id_mutation agregando superficie, habitaciones y dependencias (76.477 obs).

ETAPA 1: SELECCIÓN DE TRANSACCIÓN

Exclusión de uso comercial/industrial, operativas mixtas y múltiples viviendas principales.

2. Diseño de evaluación

Diseño de evaluación



Desarrollo

Entrenamiento (80%)+ Validación (20%)

Reserva

Prueba

Información admisible

15 variables explicativas consolidadas para estimar M_1, M_2 y M_3.

FÍSICOS Y ESTRUCTURALES

Vivienda

- **type_local**: Tipología (Maison/Appartement)
- **surface_habitable**: Superficie habitable (m²)
- **piezas_max**: Número de habitaciones
- **n_dependances**: Conteo de dependencias

ESPACIAL Y CATASTRAL

Ubicación y Terreno

- **latitude / longitude**: Coordenadas continuas
- **surface_terrain_total**: Terreno total (m²)
- **n_parcelles**: Número de parcelas
- **nombre_lots_max**: Total de lotes

USO DE SUELO (INDICADORES)

Flags Catastrales

`has_jardin` `has_sol`

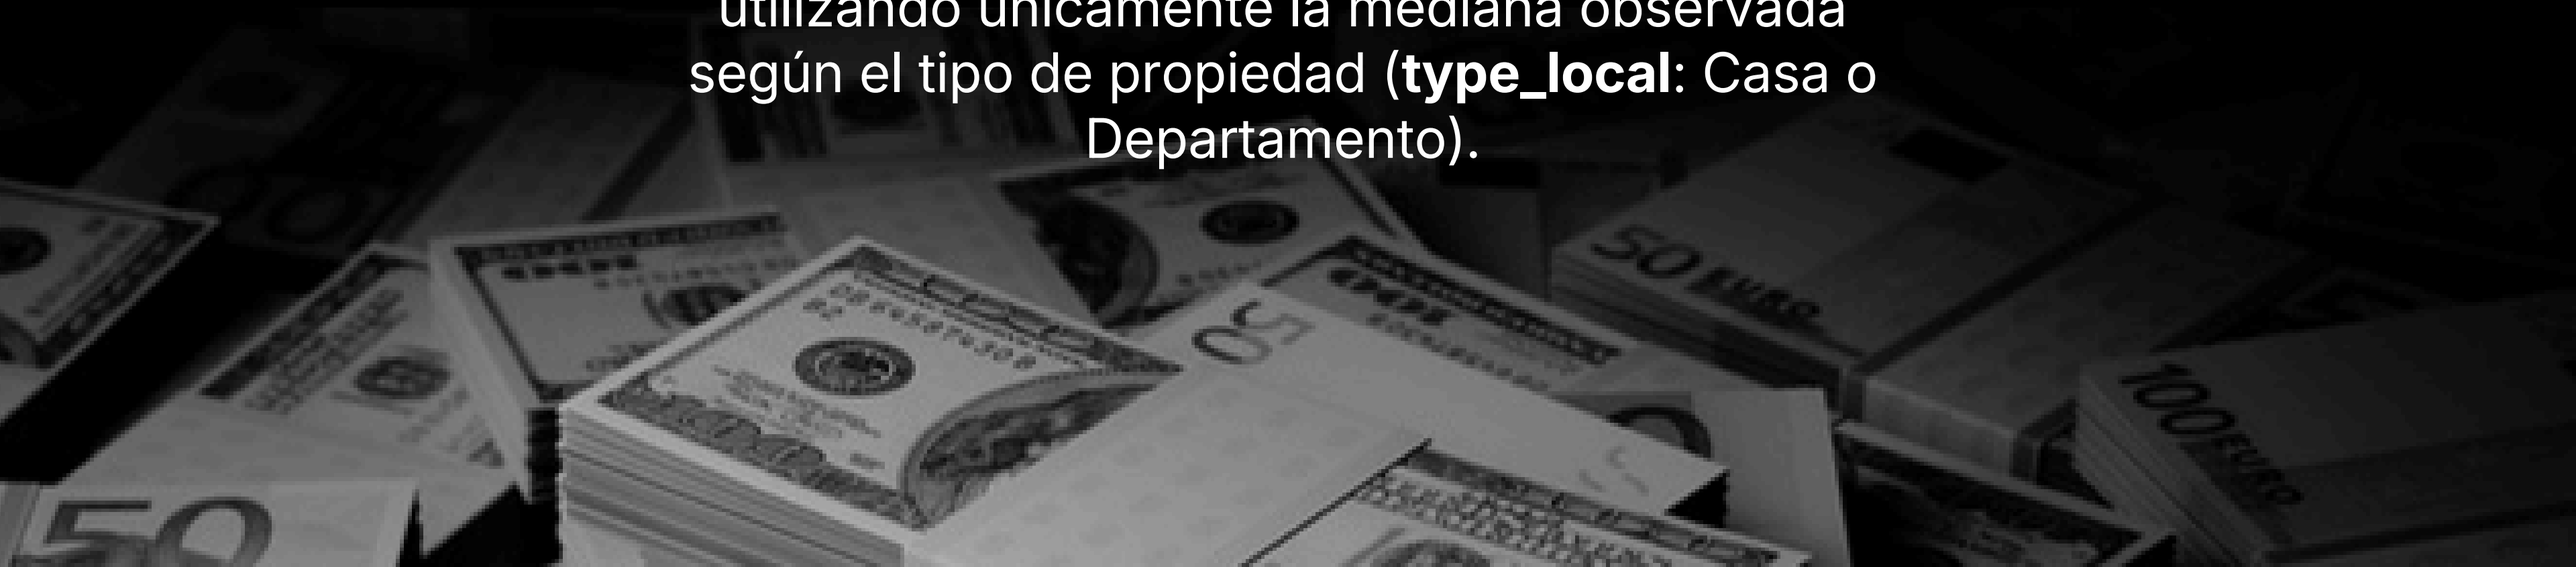
`has_terres` `has_verger`

`has_terreno_unspecified`

Modelo de referencia (M_0)

MEDIANA OBSERVADA SEGÚN EL TIPO DE PROPIEDAD

Predice el valor logarítmico del inmueble (log Y) utilizando únicamente la mediana observada según el tipo de propiedad (**type_local**: Casa o Departamento).



3. Metodología y resultados

1

M1: Regresión

Se utilizó **regresión lineal con penalización LASSO**

2

M2: Flexibilidad

Se utilizó un **modelo aditivo generalizado** (GAM)

3

M3: Ensamble

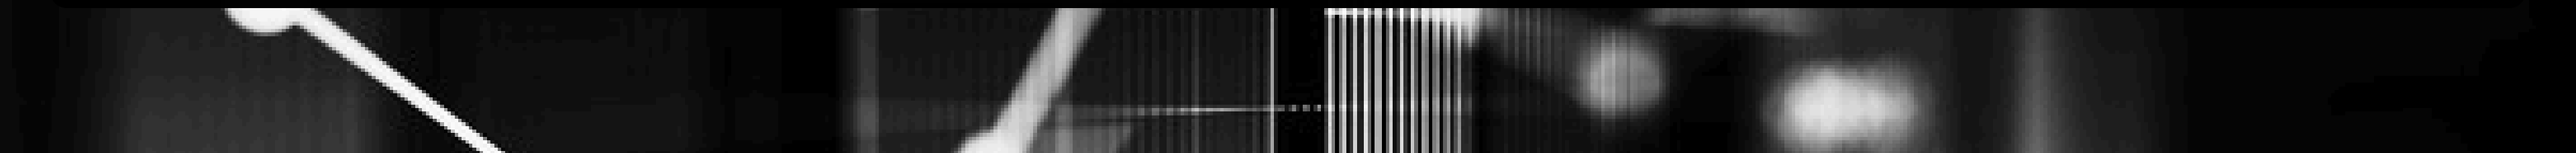
Se utilizó **XGBoost**

Comparación de resultados

Desempeño de los modelos en los conjuntos de validación y prueba

	Validación			Prueba		
Modelo	**MAE**	**RMSE**	**Mediana AE**	**MAE**	**RMSE**	**Mediana AE**
Referencia	**120.423**	**192.213**	**81.369**	**113.810**	**173.725**	**81.369**
LASSO	88.247	199.920	57.708	88.247	199.920	57.708
GAM	81.552	127.749	55.359	64.158	106.709	42.277
XGBoost	**54.237**	**94.363**	**31.966**	**53.237**	**94.363**	**31.966**

Nota: MAE, RMSE y Mediana AE se **expresan en euros (EUR).**



Importancia de variables - XGBOOST

SUPERFICIE Y UBICACIÓN DOMINAN EL PRECIO

#1

Superficie Habitable

Mayor peso predictivo absoluto en la estimación inmobiliaria.

Coordenadas Geográficas

Longitud y Latitud concentran el segundo nivel de importancia.

Atributos Físicos Secundarios

Número de lotes, dependencias y piezas con impacto acotado.

CASAS PRESENTAN EL DOBLE DE ERROR QUE APARTAMENTOS

Diagnóstico de errores por tipología



Apartamentos

42.684 €

MAE XGBoost en datos de prueba

Mayor homogeneidad en características habitacionales.

N = 14.597

Casas

90.619 €

MAE XGBoost en datos de prueba

Alta heterogeneidad en terrenos, jardines y dependencias.

N = 4.121

RESULTADOS CLAVE

Desempeño del modelo según densidad y valor de las zonas

Propiedades Top 5%

189.978 €

MAE XGBoost en datos de prueba

ventas sobre 839.000,00 €

Zonas Aisladas (≤10 ventas)

74.106 €

MAE XGBoost en datos de prueba

Escasez de antecedentes degrada la estimación

Zonas Densas (>50 ventas)

52.235 €

MAE XGBoost en datos de prueba

Alta transaccionalidad mejora la precisión

RESULTADOS CLAVE

Desempeño del modelo según dos sensibilidades

1) Escala de la variable respuesta

Variable en escala logarítmica

53.237 €

MAE XGBoost en datos de prueba

Variable en escala original

55.045 €

MAE XGBoost en datos de prueba

2) Incorporación de variables geográficas

Con latitud y longitud

53.237 €

MAE XGBoost en datos de prueba

Sin latitud y longitud

81.139 €

MAE XGBoost en datos de prueba

4. Análisis y conclusiones

Principales fuentes de incertidumbre

FILTROS DE DEPURACIÓN

Los filtros de depuración excluyen superficies menores a 8 m² y valores inferiores a 1.000 €/m².

IMPUTACIÓN COMUNAL

La imputación comunal utiliza la mediana comunal para coordenadas geográficas faltantes.

VARIABLES OMITIDAS

Las variables omitidas incluyen calidad constructiva y cercanía al transporte público.

SUBESTIMACIÓN EN LUJO

La subestimación en lujo refleja una baja representatividad del 5% de las propiedades de mayor valor.

Entorno técnico y trabajo colaborativo

El script está desarrollado en **R** y su ejecución toma entre **4 y 5 minutos**.

La fuente es **DVF Rhône**, con datos de **2021-2023**, y el proyecto se aloja en **GitHub**.

El trabajo integra depuración, consolidación de datos, modelado, validación y reporte en **LaTeX**.

F. Sepúlveda:
diseño metodológico y métricas.

A. Pinto:
depuración y consolidación DVF.

K. Armijo:
implementación de modelos LASSO, GAM y XGBoost.

P. Mella:
validación 2023, reporte LaTeX y elaboración de la presentación.

XGBoost consolida el mejor desempeño predictivo

En el conjunto de prueba, XGBoost alcanza un MAE de

53.237 €

La superficie habitable y la localización geográfica son pilares clave de la predicción.

El desempeño destacado se mantiene frente a los modelos comparados en validación y prueba.



Gracias por su atención